

DINOv3 ViT-S/16 + PSPNet 在 PASCAL VOC2012 上的语义分割实验报告

摘要

本实验使用预训练 DINOv3 ViT-S/16 作为视觉骨干，将 patch token 重排为二维特征图，随后接入 PSPNet 的 Pyramid Pooling Module (PPM) 完成 PASCAL VOC2012 的 21 类语义分割。实验比较了冻结 DINOv3 与全量微调 DINOv3 两种方案。当前最佳验证结果为冻结方案的 **81.90% mIoU** 和 **96.05% 像素准确率**；微调方案为 **72.93% mIoU** 和 **92.38% 像素准确率**。冻结方案高出 8.98 个 mIoU 百分点，并在全部 21 个类别上取得更高 IoU。训练曲线表明微调方案存在明显过拟合。不过，两组输入尺寸和 batch size 不同，当前比较不是严格的单变量消融实验，结果不能全部归因于是否解冻骨干。

1. 实验目标

实验验证 DINOv3 的预训练密集视觉特征能否迁移到 VOC2012 语义分割任务，并分析 PSPNet 分割头在冻结和微调骨干两种设置下的性能。模型数据流如下：

```
输入 [B,3,H,W]
  → DINOv3 ViT-S/16
  → patch tokens [B,(H/16)(W/16),384]
  → 二维特征 [B,384,H/16,W/16]
  → PSPNet PPM (1×1、2×2、3×3、6×6)
  → 21 类 logits
  → 双线性上采样至 [B,21,H,W]
```

训练使用逐像素交叉熵，VOC 标注中的 255 作为忽略标签。评价时先累积完整验证集混淆矩阵，再计算每类 IoU 及其宏平均 mIoU。

2. 实验设置

两组共同设置为：VOC2012 官方 train/val 划分、训练 30 epoch、随机种子 42、AdamW、head 学习率

1e-3、权重衰减 1e-4、自动混合精度，以及同一份 DINOv3 ViT-S/16 LVD-1689M 预训练权重。


设置	Frozen	Fine-tuned
DINOv3 是否训练	否	是
输入尺寸	384×384	320×320
Batch size	2	1
Head LR	1e-3	1e-3
Backbone LR	0	1e-5
Epoch	30	30
最佳 checkpoint epoch	29	24

由于显存条件导致输入尺寸和 batch size 不同，本表是“实际运行方案比较”，不是严格控制变量实验。

3. 总体结果

模型	Val loss	Pixel accuracy	mIoU	相对冻结组 mIoU
Frozen DINOv3-S + PSPNet	0.1438	96.05%	81.90%	—
Fine-tuned DINOv3-S + PSPNet	0.5007	92.38%	72.93%	-8.98 pp

冻结方案同时获得更低的 loss、更高的像素准确率和更高的 mIoU，因此是本次实验的最佳方案。微调方案的 mIoU 相对冻结方案下降约 10.96%（相对比例），绝对下降 8.98 个百分点。



冻结组验证 mIoU 从第 1 轮的 73.79% 上升到第 29 轮最佳值 81.90%，第 30 轮略回落至 80.69%。微调组第 1 轮验证 mIoU 为 67.69%，第 24 轮达到最佳 72.93%，第 30 轮为 71.89%。

保存最佳 checkpoint 而非直接使用最后一轮是正确的。

4. 逐类别 IoU

类别	Frozen	Fine-tuned	Fine-tuned – Frozen
background	95.56%	91.18%	-4.37 pp
aeroplane	88.48%	84.31%	-4.17 pp
bicycle	55.98%	50.86%	-5.12 pp
bird	90.80%	82.99%	-7.81 pp
boat	79.47%	73.47%	-6.00 pp
bottle	82.28%	80.80%	-1.47 pp
bus	93.47%	82.25%	-11.22 pp
car	86.91%	76.23%	-10.68 pp
cat	93.85%	70.47%	-23.38 pp
chair	51.44%	44.06%	-7.38 pp
cow	89.68%	79.60%	-10.08 pp
diningtable	71.64%	68.72%	-2.91 pp
dog	92.80%	81.58%	-11.22 pp
horse	83.88%	72.31%	-11.57 pp
motorbike	84.26%	78.61%	-5.65 pp
person	90.69%	79.44%	-11.25 pp
pottedplant	65.82%	49.76%	-16.06 pp
sheep	88.51%	72.52%	-15.99 pp
sofa	66.35%	53.74%	-12.61 pp
train	90.31%	80.94%	-9.37 pp
tvmonitor	77.83%	77.62%	-0.21 pp

冻结组表现最好的前景类别是 cat (93.85%)、bus (93.47%) 和 dog (92.80%); 较弱类别是 chair (51.44%)、bicycle (55.98%) 和 pottedplant (65.82%)。这些类别往往具有细结构、遮挡、尺度小或与室内背景混淆等特点, 而 ViT-S/16 的 16 像素 patch 步长会进一步限制细边界恢复。微调的最大跌幅出现在 cat (-23.38 pp)、pottedplant (-16.06 pp) 和 sheep (-15.99 pp)。

5. 过拟合分析

冻结组最佳 epoch 的训练/验证 mIoU 分别为 94.70%/81.90%, 泛化间隙约 12.80 pp; 训练/验证 loss 分别为 0.0316/0.1438。它也存在一定过拟合, 但验证性能总体随训练推进而改善。

微调组最佳 epoch 的训练/验证 mIoU 分别为 95.73%/72.93%, 泛化间隙扩大到约 22.46 pp; 训练 loss 仅 0.0266, 验证 loss 却达到 0.5007。到第 30 轮, 训练 mIoU 继续升至 96.22%, 验证 mIoU 仅为 71.89%。这说明模型并非优化失败, 而是对仅 1,464 张训练图像拟合过强, 预训练表示在全量解冻后发生了不利的任务适配或表示漂移。

可能原因包括: VOC2012 官方训练集较小; 全量微调 21M 参数的自由度过高; 数据增强只有缩放与水平翻转; 320 输入比冻结组的 384 输入少约 30.6% 的像素, 也减少了小目标和边界信息; batch 1 会令 PSP head 中 BatchNorm 的统计量更不稳定。因此当前结果支持“冻结更稳健”, 但尚不能独立证明“微调本身必然降低性能”。

6. 结论

本实验成功实现了 DINOv3 ViT-S/16 与 PSPNet 的迁移学习语义分割系统。冻结 DINOv3 时, 仅训练 PSPNet 头即可在 VOC2012 val 上达到 81.90% mIoU, 说明 DINOv3 的预训练 patch 特征具有很强的密集预测迁移能力。在当前资源和配置下, 全量微调不仅没有提升结果, 反而产生明显过拟合, 最佳 mIoU 低 8.98 个百分点。因此, 本次实验最终推荐 **Frozen DINOv3-S + PSPNet**。

7. 有效性限制与后续实验

1. 两组应在相同的 384×384 输入和相同 batch size (可用梯度累积模拟) 下重跑, 形成严格消融。
2. 微调可改为只解冻最后 2–4 个 Transformer block, 而不是全量解冻。
3. 可将 backbone LR 从 1e-5 降至 1e-6, 并采用 warm-up、layer-wise learning-rate decay。
4. 增加随机尺度、随机裁剪、颜色扰动等增强, 并更早 early stopping。
5. batch 1 时可冻结 head 的 BatchNorm 统计量或改用 GroupNorm。
6. 当前结果来自反复用于选最佳 checkpoint 的 val 集, 应称为验证结果; 若需要无偏最终成绩, 应另设测试集或提交 VOC 官方 test server。

8. 可复现依据

- 原始总体指标： `outputs/frozen/evaluation.json` 、 `outputs/finetuned/evaluation.json`
- 完整训练记录： `outputs/frozen/history.json` 、 `outputs/finetuned/history.json`
- 最佳模型：冻结组 epoch 29，微调组 epoch 24
- 曲线生成：运行 `python analyze_results.py`